


機器學習 HW2 part2

工科系 111 E94071209 林政旭

Question 3.0:

下圖橫軸為 w_1 ，設定 w_0 為定值的 likelihood 圖，由下圖可知不管 w_0 為何，當 w_1 越大時，likelihood function 的值皆會越大，並越來越趨近於 1，因此，不存在 unique 的一組 w_0 及 w_1 使得 likelihood value 有最大值。




下圖為 sigmoid、likelihood、Normal weight prior 之 $P[w]$ 與 Laplace weight prior 之 $P[w]$ 的程式圖，並設定 x 為在 -5 至 5 之間的 2000 個分布點


```
def sigmoid(x):  
    return 1/(1+np.exp((-x)))  
def likelihood(w0,w1):  
    return sigmoid(w1+w0)*sigmoid(w1-w0)  
def normalp(w):  
    return np.exp(-np.power(w,2)/2)/np.power(2*np.pi,0.5)  
def laplacep(w):  
    return np.exp(-np.abs(w))/2  
  
x = np.linspace(-5,5,2000)
```

Question 3.1

1. 下圖橫軸為 w_0 ，縱軸為 $P[w_0]$ 之圖，由圖可知最大值發生在 $w_0=0$ ；對其微分可得 $dP[w_0]$ ，另其=0，用程式跑發現最大值發生在-0.0025(非常接近 0)，且 $P[w_0]$ 最大值=0.398941



2.



3. 在 $w_0=w_{0map}=-0.002501250625313034$ 時，使用程式跑出來 w_1 最大值發生在 0.672836418209104


```
#3.1.3
w1max=np.argmax(likelihood(-0.002501250625313034,x)*p(x))
print('3.1.3:',x[w1max])#最大值發生在w1=0.672836418209104
```

4. 在 $w_0=w_{0map}=-0.002501250625313034$ 時，posterior mean of w_1 為 0.7042758569261673


```
#3.1.4
temp=0
for i in range(len(x)):
    temp+=likelihood(-0.002501250625313034,x[i])*p(x[i])
posteriormean=0
for i in range(len(x)):
    posteriormean+=x[i]*likelihood(-0.002501250625313034,x[i])*p(x[i])
posteriormean/=temp
print('3.1.4:',posteriormean)#posterior mean為0.7042758569261673
```

Question 3.2:

1. 下圖橫軸為 w_0 ，縱軸為 $P[w_0]$ 之圖，由圖可知最大值發生在 $w_0=0$ ；對其微分可得 $dP[w_0]$ ，另其=0，用程式跑發現最大值發生在 0.002501250625312146 (非常接近 0)，且 $P[w_0]$ 最大值=0.4987509374477932



2.



3. 以分析的角度去求最大值的 w_1 的話，首先可先將 $P[d, w_1|w_{0map}]$ 拆成 $w_1 \geq 0$ 與 $w_1 < 0$ 兩個部分，又因為 w_{0map} 約等於 0，所以第一部分 $w_1 \geq 0$ ，可將式子約略化簡成 $(\frac{1}{1+e^{-w_1}})^2 * \frac{e^{-w_1}}{2}$ ，接著再化簡成 $\frac{0.5}{2+e^{w_1}+e^{-w_1}}$ ，因 $\exp(-w_1)$ 在 $0 \sim 1$ 之間，所以主要看 $\exp(w_1)$ 項，而因為 w_1 越大， $\exp(w_1)$ 越大，整個 function 值就會越小，所以當 w_1 為 0 時，function 有最大值 1/8；接著看第二部分 $w_1 < 0$ ，可將式子化簡成 $(\frac{1}{1+e^{-w_1}})^2 * \frac{e^{w_1}}{2}$ ，接著進一步化簡成

$\frac{0.5}{e^{-w_1}+2e^{-2w_1}+e^{-3w_1}}$ ，當 w_1 越來越小時，整個 function 值也會越來越小，而當 $w_1=0$ 時，function 有最大值 1/8，因此，根據夾擠定理(Squeeze theorem)， $P[d, w_1|w_{0map}]$ 的最大值為 1/8，且發生在 0 的位置。


下圖為使用程式在 $w_0=w_{0map}=0.002501250625312146$ 時， w_1 最大值發生在 0.002501250625312146 ，且最大值為 0.12499960898510112，約等於 1/8

```
#3.2.3
w1max=np.argmax(likelihood(0.002501250625312146,x)*p(x))
print('3.2.3:',x[w1max])#最大值發生在w1=0.002501250625312146
```


4. 在 $w_0=w_{0map}=0.002501250625312146$ 時，posterior mean of w_1 為 0.9963922458605604

```
#3.2.4
temp=0
for i in range(len(x)):
    temp+=likelihood(0.002501250625312146,x[i])*p(x[i])
posteriormean=0
for i in range(len(x)):
    posteriormean+=x[i]*likelihood(0.002501250625312146,x[i])*p(x[i])
posteriormean/=temp
print('3.2.4:',posteriormean)#posterior mean為0.9963922458605604
```

下圖為 $P[\text{class} = Y | x, w_0, w_1]$ ，其中 $w_0=w_{0map}$ ， $w_1=\text{posterior mean}$ ，由圖中可看到，在 $x = -1$ 時，Laplace weight prior = 0.270144218660314，Normal weight prior = 0.3303113723034824，皆小於 0.5，表示其皆可成功判斷在 $x = -1$ 時，其有較大的概率不是 class Y，而其中，又以 Laplace weight prior 的表現比 Normal weight prior 要來的好一些。



下圖的綠色、紅色部分為用 $w_1 = w_{1map}$ 來做圖，可以看到 Laplace weight prior with w_{1map} 已經變成一條直線了，若使用它來預測 class N 和 class Y 將會非常不準確，Normal weight prior with w_{1map} 則是與 posterior mean 的 w_1 相差不大



因為 $P[w_1|w_{0MAP}, d] = c * P[d|w_{0MAP}, w_1] P[w_1]$ ，所以當 $P[w_1]$ 為不同的 prior 時，會導致 $P[w_1|w_{0MAP}, d]$ 不同，而導致產生不同的 w_{1map} 以及不同的 posterior mean of w_1 ，預測的精確度也會跟著 w_1 的不同而有所影響

在 small datasets 的情況下，一般而言標準差是會比較大的，若是所有抽樣的 class Y 的 datasets 的 x 值皆大於 0，那麼我們可能就會有先入為主想法去限定條件如 $P[class = Y | x < 0, w] = 0$ ，這會使 $x < 0$ 不產生任何機率，對於我們預測其結果來說是不利的，因為我們會損失掉所有 $x < 0$ 的可能性，因此，常態分布很常被使用，因為它可以集中小範圍的數據，且對於任何 x 值都保有一定的機率，永不歸零。